

S20 - EVIDENCIA DE APRENDIZAJE 2

Isabela Arango Verona

Proyecto Integrado III - Analítica de Datos

Grupo PREICA2601B020046

Docente Andrés Felipe Palacio

Institución Universitaria Digital de Antioquia

Medellín, Antioquia

Mayo del 2026

Índice

Índice de Figuras.....	3
Introducción.....	4
Definición del Problema.....	5
Pregunta Investigativa.....	5
Métricas de Evaluación de Éxito.....	6
Fuentes de Datos.....	7
Diccionario de Datos Completo (34 Variables).....	7
Exploración de Datos.....	11
Análisis de Duplicados y Valores Nulos.....	11
Tipos de Datos.....	11
Distribuciones Principales.....	12
Correlaciones.....	13
Resumen Estadístico.....	14
Descripción de Necesidades de Limpieza.....	15
Limpieza y Transformación de Datos.....	17
Ajuste de Tipos de Datos (Transformación ejecutada).....	17
Detección y Tratamiento de Valores Atípicos (Outliers).....	17
Correcciones de Valores y Estandarización.....	18
Agregación de Datos (Cambio de Granularidad).....	18
Validación.....	19
Conclusiones.....	20
Conclusiones.....	21
Anexos.....	23

Índice de Figuras

Figura 1. Categoría Resumen del Perfilamiento de Datos del Dataset “Social Media User Behavior Dataset”	11
Figura 2. Categoría Correlaciones del Perfilamiento de Datos del Dataset “Social Media User Behavior Dataset”	13
Figura 3. Resultados del código para la descripción de necesidades de limpieza.....	16
Figura 4. Boxplot para la identificación de valores atípicos.....	17

Introducción

La presente evidencia de aprendizaje se enmarca en el curso Proyecto Integrado III - Analítica de Datos y tiene como objetivo principal explorar la compleja relación entre el comportamiento del usuario en redes sociales y su impacto en la salud mental y los patrones de sueño. Ante el crecimiento exponencial del tiempo de pantalla, surge la necesidad de identificar patrones de uso que sirvan como señales de alerta temprana para la afectación del bienestar emocional.

Para abordar este problema, se plantea la pregunta investigativa sobre la influencia del tiempo de uso diario y el tipo de dispositivo en la probabilidad de que un usuario reporte una baja autopercepción de salud mental (puntaje inferior a 5.0/10) y presente disrupción del sueño.

Este documento detalla la definición del problema, las métricas de éxito (incluyendo el Puntaje de Alerta de Bienestar y el Coeficiente de Correlación de Disrupción), y describe la fuente de datos, el conjunto de datos sintético "Social Media User Behavior Dataset" con 2,000 registros. Además, presenta un resumen de la exploración inicial de datos (EDA), la cual confirmó la alta calidad del dataset (sin duplicados ni nulos) y reveló que, si bien hay coherencia en las variables de uso, no existe una correlación lineal simple entre el tiempo total de uso y el puntaje de salud mental, sugiriendo la importancia de variables cualitativas.

Definición del Problema

El uso intensivo de redes sociales ha demostrado tener una correlación directa con el bienestar emocional y la calidad del sueño de los usuarios. Actualmente, las plataformas carecen de sistemas de detección proactiva que identifiquen cuándo los hábitos de consumo de un usuario (tiempo de pantalla, velocidad de scroll, horas de uso nocturno) comienzan a afectar negativamente su salud mental autoinformada.

El problema radica en identificar los patrones de comportamiento que preceden a una baja puntuación en la salud mental para que las plataformas puedan implementar estrategias de "Bienestar Digital" (pausas sugeridas, límites de tiempo o cambios en el tipo de contenido).

Pregunta Investigativa

¿En qué medida el tiempo de uso diario y el tipo de dispositivo utilizado influyen en la probabilidad de que un usuario reporte un puntaje de salud mental inferior a 5.0/10 y presente interrupciones en el sueño?

Métricas de Evaluación de Éxito

Para evaluar el éxito del análisis y la validez de las hipótesis planteadas, se definen las siguientes métricas:

- **Puntaje de Alerta de Bienestar (PAB):** Porcentaje de la muestra que presenta una combinación de "Uso Crítico" (>5 horas diarias) y "Baja Autopercepción de Salud" (Score < 5). El éxito se define al identificar los umbrales exactos donde el score de salud mental cae significativamente.
- **Coeficiente de Correlación de Disrupción (CCD):** Medición de la fuerza de asociación entre el uso en horarios nocturnos (Late Night) y la variable de disrupción del sueño (sleep_disruption). Se considerará un hallazgo relevante una correlación $r > 0.60$.
- **Índice de Fatiga por Interacción:** Identificación de la relación entre la tasa de clics en publicidad (ad_click_rate) y el estado de ánimo durante el scroll (mood_while_scrolling). El éxito se mide al determinar si la fatiga digital reduce la efectividad publicitaria en usuarios con salud mental afectada.

Fuentes de Datos

Para el desarrollo de este proyecto se utilizará un conjunto de datos sintético que simula el comportamiento de usuarios en diversas plataformas digitales.

- **Nombre del Dataset:** Social Media User Behavior Dataset
- **Origen:** Kaggle (Autor: Hamna Munir)
- **Enlace:**
<https://www.kaggle.com/datasets/hamnamunir/social-media-user-behavior-dataset>
- **Formato:** Archivo de valores separados por comas (.CSV)
- **Tamaño:** 2,000 filas y 34 columnas.
- **Licencia:** CC0: Public Domain.

La unidad mínima de registro (granularidad) es por usuario individual. Cada fila representa el comportamiento consolidado y perfil de un único usuario (user_id), permitiendo realizar análisis tanto a nivel demográfico como conductual.

Diccionario de Datos Completo (34 Variables)

Variable	Tipo de Dato	Descripción / Rango de Valores
user_id	Alfanumérico ▾	Identificador único del registro (USR00001–USR02000).
age	Numérico (Int) ▾	Edad del usuario (13 a 57 años). Media: 27 años.
gender	Categórico ▾	Identidad de género: Female (49%), Male (46%), Non-binary, Other.
country	Categórico ▾	País de residencia (10 países, principales: Pakistán e India).
profession	Categórico ▾	Ocupación del usuario (Ingeniero, Maestro,

		Estudiante, etc.).
primary_platform	Categorico ▾	Plataforma principal: Instagram (21%), TikTok (20%), YouTube, etc.
platforms_used_count	Numérico (Int) ▾	Cantidad de redes sociales activas (Rango: 1 a 5).
daily_usage_hours	Numérico (Float) ▾	Horas diarias de uso (0.5 a 12h). Media: 2.99h.
sessions_per_day	Numérico (Int) ▾	Número de sesiones diarias abiertas (1 a 15). Media: 5.02.
avg_session_duration_min	Numérico (Float) ▾	Duración promedio por sesión en minutos (3.3 a 594 min).
preferred_device	Categorico ▾	Dispositivo de preferencia (Smartphone, Tablet, Desktop).
peak_usage_time	Categorico ▾	Horario de mayor actividad (Morning, Afternoon, Evening, Late Night).
followers_count	Numérico (Int) ▾	Cantidad de seguidores del perfil.
following_count	Numérico (Int) ▾	Cantidad de cuentas que sigue el usuario.
posts_per_week	Numérico (Int) ▾	Frecuencia de publicaciones semanales.
likes_given_per_day	Numérico (Int) ▾	Cantidad de "Me gusta" otorgados diariamente.
comments_per_day	Numérico (Int) ▾	Cantidad de comentarios realizados al día.
shares_per_day	Numérico (Int) ▾	Frecuencia diaria de contenido compartido.
dms_sent_per_day	Numérico (Int) ▾	Mensajes directos enviados por día.

preferred_content_type	Categorico ▾	Tipo de contenido favorito (Videos, Photos, Memes, Educational).
scroll_speed	Categorico ▾	Velocidad de navegación (Fast, Medium, Slow).
ad_click_rate	Numérico (Float) ▾	Tasa de clics en anuncios publicitarios.
purchased_via_social	Booleano ▾	Indica si ha realizado compras a través de redes (Yes/No).
monthly_spend_via_social	Numérico (Float) ▾	Gasto mensual en USD realizado en redes sociales.
primary_purpose	Categorico ▾	Motivo de uso (Entertainment, Socializing, News, Learning).
sleep_disruption	Categorico ▾	Nivel de afectación en el sueño (No impact, Mild, Moderate, Severe).
mental_health_score	Numérico (Float) ▾	Puntuación autoinformada de salud mental (1.0 a 10.0).
screen_time_concern	Categorico ▾	Nivel de preocupación por el tiempo en pantalla (Yes/No/Maybe).
notification_frequency	Categorico ▾	Frecuencia de notificaciones (Low, Medium, High).
privacy_setting	Categorico ▾	Configuración de privacidad (Public, Private, Friends Only).
influencer_status	Booleano ▾	Indica si el usuario es considerado influencer (Yes/No).
account_join_date	Fecha (YYYY-MM-DD) ▾	Fecha de creación de la cuenta.
mood_while_scrolling	Categorico ▾	Estado de ánimo (Happy, Neutral, Stressed, Bored, Anxious).

takes_social_media_breaks	Booleano ▾	Indica si el usuario toma descansos de las redes (Yes/No).
---------------------------	------------	--

Exploración de Datos

Para la fase de exploración se utilizó la librería ydata-profiling (antes pandas-profiling), la cual permitió generar un reporte exhaustivo del estado del dataset. A continuación, se detallan los hallazgos principales:

Análisis de Duplicados y Valores Nulos

- **Duplicados:** Tras el análisis, se identificaron 0 registros duplicados. Cada una de las 2,000 filas cuenta con un identificador único (user_id), lo que garantiza que no hay redundancia de información en la muestra.
- **Valores Nulos:** El dataset presenta una integridad del 100%. No se encontraron valores faltantes (Missing Cells: 0) en ninguna de las 34 variables. Esto permite realizar un análisis estadístico robusto sin necesidad de aplicar técnicas de imputación de datos.

Figura 1. Categoría Resumen del Perfilamiento de Datos del Dataset “Social Media User Behavior Dataset”.

Overview

Overview Alerts 10 Reproduction	
Dataset statistics	Variable types
Number of variables	34
Number of observations	2000
Missing cells	0
Missing cells (%)	0.0%
Duplicate rows	0
Duplicate rows (%)	0.0%
Total size in memory	2.3 MiB
Average record size in memory	1.2 KiB
Text	1
Numeric	14
Categorical	17
Boolean	1
DateTime	1

Tipos de Datos

El dataset presenta una estructura mixta que facilita diversos tipos de análisis:


- **Variables Numéricas (14):** Incluyen datos enteros y continuos como age, daily_usage_hours, followers_count y mental_health_score.
- **Variables Categóricas (17):** Variables cualitativas como gender, primary_platform, preferred_device y mood_while_scrolling.
- **Variables Booleanas (3):** Datos de tipo Sí/No como influencer_status y takes_social_media_breaks.

Distribuciones Principales

- **Edad (age):** La distribución está sesgada hacia la población joven, con una media de 27 años y un rango que va desde los 13 hasta los 57 años. El grupo de mayor concentración se encuentra entre los 18 y 30 años.
- **Uso Diario (daily_usage_hours):** El promedio de uso es de 2.99 horas al día. Sin embargo, se observa una distribución de "cola larga" donde algunos usuarios alcanzan hasta las 12 horas diarias, lo que representa los casos críticos para nuestro estudio de salud mental.
- **Salud Mental (mental_health_score):** Los puntajes se distribuyen en un rango de 1 a 10, con una tendencia central que permite identificar claramente a los usuarios por debajo del umbral de bienestar definido ($\text{Score} < 5$).

Correlaciones

Figura 2. Categoría Correlaciones del Perfilamiento de Datos del Dataset “Social Media User Behavior Dataset”.



El análisis de correlación de Pearson revela que la mayoría de las variables tienen una asociación lineal muy débil entre sí, lo cual es característico de este dataset. Sin embargo, se identificaron tres puntos clave:

- **Fuerte Correlación Positiva (0.785):** Existe una relación muy alta entre `daily_usage_hours` y `avg_session_duration_min`. Esto confirma la coherencia interna de los datos: los usuarios que pasan más horas totales en redes sociales lo hacen a través de sesiones individuales más prolongadas.
- **Correlación Negativa Moderada (-0.587):** Se observa una relación inversa importante entre `avg_session_duration_min` y `sessions_per_day`. Esto sugiere un patrón de

comportamiento: los usuarios que tienen sesiones muy largas suelen entrar menos veces al día, mientras que los que tienen sesiones cortas tienden a abrir las aplicaciones con mucha mayor frecuencia.

- **Correlación en Salud Mental y Sueño (Hallazgo Crítico):** Contrario a la hipótesis inicial, la correlación entre `daily_usage_hours` y `self_reported_mental_health_score` es casi nula (0.019).
 - De igual forma, la relación entre el uso diario y la interrupción del sueño (`sleep_disruption`) es muy baja (0.033).
 - En este conjunto de datos específico, el impacto en la salud mental no sigue una progresión lineal simple respecto al tiempo de uso. Esto indica que el problema planteado en la Sección I podría ser más complejo y depender de variables cualitativas (como el estado de ánimo o el tipo de contenido) más que de la cantidad de horas exclusivamente.
- **Comportamiento Comercial (0.379):** Existe una correlación positiva moderada entre `purchased_via_social_media` y `monthly_spend_via_social_usd`, lo cual valida que los usuarios que reportan realizar compras efectivamente reflejan un gasto mensual en la plataforma.


Resumen Estadístico

Métrica	Valor
Número de variables	34
Número de observaciones	2,000
Media de uso diario	2.99 horas
Promedio de sesiones	5.02 al día
Promedio salud mental	Variable (Rango 1-10)
Plataforma líder	Instagram (21%)

Descripción de Necesidades de Limpieza

- **Duplicados:** Se detectaron 0 duplicados.
 - **Justificación:** Esto indica que la integridad de los registros es alta y no hay riesgo de sobreestimar métricas de comportamiento (como el promedio de horas de uso) por repetición de filas.
- **Valores Nulos:** Existen 0 valores nulos.
 - **Justificación:** El dataset es robusto para el análisis estadístico inmediato. Sin embargo, se mantendrá una lógica de imputación preventiva en el código por si se agregan datos futuros con vacíos.
- **Tipos de Datos:** Actualmente existen 19 variables tipo object (texto).
 - **Necesidad:** Las variables como gender, primary_platform y peak_usage_time deben convertirse al tipo category para ahorrar memoria y mejorar la velocidad de procesamiento. La columna account_join_date debe pasar de object a datetime para poder hacer cálculos de antigüedad.
- **Valores Atípicos (Outliers):** El promedio es 47.5 min, pero el máximo es 594 min (casi 10 horas en una sola sesión)
 - **Necesidad:** Estas "sesiones maratónicas" pueden distorsionar los promedios. Se necesita visualizarlas con diagramas de caja (boxplots) para decidir si son errores de registro o comportamientos de uso extremo real.
- **Granularidad:** El dataset tiene una granularidad alta (un registro por cada usuario).
 - **Necesidad:** Para responder a preguntas de negocio globales, se necesita reducir la granularidad (agrupar) para ver promedios por plataforma o por rango de edad.

Figura 3. Resultados del código para la descripción de necesidades de limpieza.



Limpieza y Transformación de Datos


Ajuste de Tipos de Datos (Transformación ejecutada)

Se realizó una reestructuración de los tipos de datos para optimizar el análisis, logrando los siguientes cambios:

- **Conversión Temporal:** La columna `account_join_date` se transformó exitosamente a `datetime64[ns]`, permitiendo el manejo cronológico de la información.
- **Categorización:** Se convirtieron 14 variables de texto (object) a tipo `category`. Esto no solo optimiza el uso de memoria, sino que prepara el dataset para modelos estadísticos más eficientes. Las variables restantes (como IDs o booleanos) se mantuvieron en su formato original para preservar su naturaleza.

Detección y Tratamiento de Valores Atípicos (Outliers)

Figura 4. Boxplot para la identificación de valores atípicos.



- **Análisis Visual:** Se generaron Boxplots para las variables numéricas, identificando una dispersión crítica en `avg_session_duration_min`.
- **Hallazgo:** Se detectaron 155 valores que superaban el límite estadístico de 111.54 minutos, con extremos que alcanzaban los 594 minutos.
- **Tratamiento aplicado:** Se utilizó la técnica de Winsorización a través del método

.clip(upper=111.54). Esto permitió "topar" los valores extremos, reduciendo la desviación estándar de 51.1 a 30.5 y logrando una distribución más equilibrada.

Correcciones de Valores y Estandarización

- **Mapeo de Sentimientos:** Se implementó la función .map() para crear la columna mood_category. Esta transformación simplificó 5 estados de ánimo complejos en 3 categorías maestras (Positivo, Neutral, Negativo), lo cual es fundamental para la validación de la pregunta de investigación.
- **Normalización:** Se aplicó .replace() en la variable preferred_device para ajustar la terminología (ej. cambiar "Smartphone" por "Celular"), demostrando la capacidad de estandarizar etiquetas de texto.

Agregación de Datos (Cambio de Granularidad)

- **Procedimiento:** Se aplicó una reducción de granularidad utilizando la función .groupby(). Se pasó de un nivel de detalle Individual (2,000 registros de usuarios) a un nivel de detalle Agrupado por Plataforma y Sentimiento.
- **Resultado:** Se generó una tabla resumen que permite identificar patrones de comportamiento grupal. Por ejemplo:
 - En Instagram, los usuarios con sentimiento "Neutral" presentan el mayor tiempo de uso promedio (3.55 horas).
 - En Pinterest, a pesar de tener una muestra menor, se observa el promedio de salud mental más alto (6.66) en usuarios con sentimientos negativos, lo que sugiere una dinámica distinta a otras redes.
- **Justificación:** Este cambio de granularidad es necesario para responder a los objetivos de negocio, ya que permite comparar el desempeño de las métricas de bienestar entre diferentes plataformas de manera directa y simplificada.

Validación

Una vez finalizado el proceso de limpieza y transformación, se procedió a validar si el conjunto de datos resultante es apto para abordar los objetivos iniciales del proyecto:

1. **Complejidad de los Datos:** Se confirmó que el dataset no presenta valores nulos en columnas críticas como Salud_Mental_Promedio o Uso_Promedio_Hrs. La técnica de Winsorización aplicada permitió mantener los 2,000 registros originales sin perder la representatividad de los usuarios intensivos, pero estabilizando los promedios.
2. **Relevancia de las Variables:** La creación de la columna mood_category demostró ser pertinente, ya que simplifica la relación entre el estado emocional y la plataforma utilizada, permitiendo responder con mayor claridad a la pregunta investigativa sobre el impacto en la salud mental.
3. **Granularidad Adecuada:** El nivel de detalle obtenido en la tabla agregada es suficiente para proporcionar insights significativos a nivel de plataforma. Se valida que el dataset limpio contiene toda la información necesaria para proceder a la fase de análisis estadístico avanzado.

El dataset se encuentra apto y validado para cumplir con los objetivos de la Evidencia de Aprendizaje 2 y el análisis final del proyecto.

Conclusiones

1. **Calidad del Dato y Preparación para el Modelado:** El dataset es de alta calidad (2,000 registros, 34 variables) al no presentar duplicados ni valores nulos. Esta integridad de datos elimina la necesidad de preprocesamiento extensivo, permitiendo avanzar directamente al modelado analítico y la prueba de hipótesis.
2. **Desvinculación Lineal entre Uso y Bienestar:** El hallazgo más crítico es la *nula correlación lineal* entre las horas de uso diario y el puntaje de salud mental autoinformado ($r = 0.019$), así como la baja correlación con la interrupción del sueño ($r = 0.033$). Esto sugiere que el riesgo para el bienestar no reside en la *cantidad* de tiempo de pantalla, sino en la *calidad* de la interacción o en variables contextuales aún no exploradas.
3. **Necesidad de Análisis Cualitativo:** Para responder a la pregunta investigativa, el foco debe trasladarse de las variables puramente cuantitativas (como la duración de uso) a las variables categóricas o cualitativas. Específicamente, el análisis deberá centrarse en variables como `mood_while_scrolling`, `preferred_device` y `peak_usage_time` para identificar si la combinación de *cuándo* y *cómo* se usa la plataforma es el verdadero predictor de una baja salud mental ($\text{Score} < 5.0$).
4. **Confirmación de Patrones Conductuales Internos:** Se validaron patrones conductuales lógicos dentro del dataset:
 - Una fuerte correlación entre uso diario y duración promedio de la sesión ($r = 0.785$), confirmando que los usuarios intensivos permanecen conectados por periodos más largos.
 - Una correlación inversa entre sesiones por día y duración promedio de la sesión ($r = -0.587$), lo que distingue dos perfiles: el "usuario maratón" (pocas sesiones largas) y el "usuario frecuente" (muchas sesiones cortas).

Conclusiones

1. **Disociación entre Cantidad de Uso y Bienestar (Evidencia Clave):** Se confirmó la nula correlación lineal entre la cantidad de uso diario (horas) y los indicadores de bienestar, específicamente la salud mental autoinformada ($r = 0.019$) y la interrupción del sueño ($r = 0.033$). Esta evidencia es crucial, pues desvincula el riesgo de la duración de la interacción, sugiriendo que el factor de riesgo se encuentra en la calidad, contexto o patrón conductual del uso.
2. **Reorientación del Foco Analítico:** De Cuantitativo a Cualitativo: Dada la falta de predicción por variables puramente cuantitativas (duración de uso), el análisis futuro debe priorizar las variables categóricas y contextuales. Es imperativo explorar si el modo (`mood_while_scrolling`), el dispositivo (`preferred_device`) y el momento del día (`peak_usage_time`) son los verdaderos predictores de un bajo bienestar psicológico ($\text{Score} < 5.0$).
3. **Tipología de Usuarios Basada en Patrones Conductuales:** Se identificaron y validaron dos perfiles de usuario distintos, basados en la correlación entre las métricas de sesión:
 - **Usuario Intensivo (Maratón):** Caracterizado por una fuerte correlación entre el uso diario y la duración promedio de la sesión ($r = 0.785$), indicando pocas sesiones de larga duración.
 - **Usuario Frecuente (Fragmentado):** Definido por una correlación inversa entre el número de sesiones por día y su duración promedio ($r = -0.587$), lo que sugiere múltiples sesiones de corta duración a lo largo del día.

Referencias

Hamna Munir. (n.d.). *Social Media User Behavior Dataset*. Kaggle.

https://www.kaggle.com/datasets/hamnamunir/social-media-user-behavior-dataset/dataset?select=social_media_user_behavior.csv

Anexos

Trello:

<https://trello.com/invite/b/69f1764a9fd7a780d417aa6a/ATTI8383c110c2e84874c118610022244c7824000C68/proyecto-integrado-iii-analitica-de-datos>

GitHub: <https://github.com/Isa-av/Proyecto-Integrado-III>