

PROYECTO INTEGRADOR

Isabela Arango Verona

Proyecto Integrado III - Analítica de Datos

Grupo PREICA2601B020046

Docente Andrés Felipe Palacio

Institución Universitaria Digital de Antioquia

Medellín, Antioquia

Junio del 2026

Índice

Índice de Figuras.....	3
Introducción.....	4
Definición del Problema.....	5
Pregunta Investigativa.....	5
Métricas de Evaluación de Éxito.....	6
Fuentes de Datos.....	7
Diccionario de Datos Completo (34 Variables).....	7
Exploración de Datos.....	11
Análisis de Duplicados y Valores Nulos.....	11
Tipos de Datos.....	11
Distribuciones Principales.....	12
Correlaciones.....	13
Resumen Estadístico.....	14
Descripción de Necesidades de Limpieza.....	15
Limpieza y Transformación de Datos.....	17
Ajuste de Tipos de Datos (Transformación ejecutada).....	17
Detección y Tratamiento de Valores Atípicos (Outliers).....	17
Correcciones de Valores y Estandarización.....	18
Agregación de Datos (Cambio de Granularidad).....	18
Validación.....	19
Análisis de Datos, Exploración del Dataset y Validación de Hipótesis.....	20
Análisis Analítico del Tablero: Página 1 (Perfil del Consumidor y Tipologías de Uso).....	20
Análisis de Impacto y Validación de Hipótesis: Página 2 (Salud Mental y Bienestar).....	21
Validación de la Hipótesis 1 (H1).....	22
Validación de la Hipótesis 2 (H2).....	23
Descubrimientos Inesperados y Hallazgos Cualitativos.....	23
Conclusiones.....	24
Anexos.....	25

Índice de Figuras

Figura 1. Categoría Resumen del Perfilamiento de Datos del Dataset “Social Media User Behavior Dataset”	11
Figura 2. Categoría Correlaciones del Perfilamiento de Datos del Dataset “Social Media User Behavior Dataset”	13
Figura 3. Resultados del código para la descripción de necesidades de limpieza.....	16
Figura 4. Boxplot para la identificación de valores atípicos.....	17
Figura 5. Vista general del análisis demográfico y tipologías de usuario en Power BI.....	20
Figura 6. Matriz de mapa de calor e indicadores de validación de hipótesis en Power BI.....	22
Figura 7. Pantallazo del tablero en Trello.....	25

Introducción

La presente evidencia de aprendizaje se enmarca en el curso Proyecto Integrado III - Analítica de Datos y tiene como objetivo principal explorar la compleja relación entre el comportamiento del usuario en redes sociales y su impacto en la salud mental y los patrones de sueño. Ante el crecimiento exponencial del tiempo de pantalla, surge la necesidad de identificar patrones de uso que sirvan como señales de alerta temprana para la afectación del bienestar emocional.

Para abordar este problema, se plantea la pregunta investigativa sobre la influencia del tiempo de uso diario y el tipo de dispositivo en la probabilidad de que un usuario reporte una baja autopercepción de salud mental (puntaje inferior a 5.0/10) y presente interrupción del sueño.

Este documento detalla la definición del problema, las métricas de éxito (incluyendo el Puntaje de Alerta de Bienestar y el Coeficiente de Correlación de Interrupción), y describe la fuente de datos, el conjunto de datos sintético "Social Media User Behavior Dataset" con 2,000 registros. Además, presenta un resumen de la exploración inicial de datos (EDA), la cual confirmó la alta calidad del dataset (sin duplicados ni nulos) y reveló que, si bien hay coherencia en las variables de uso, no existe una correlación lineal simple entre el tiempo total de uso y el puntaje de salud mental, sugiriendo la importancia de variables cualitativas.

Definición del Problema

El uso intensivo de redes sociales ha demostrado tener una correlación directa con el bienestar emocional y la calidad del sueño de los usuarios. Actualmente, las plataformas carecen de sistemas de detección proactiva que identifiquen cuándo los hábitos de consumo de un usuario (tiempo de pantalla, velocidad de scroll, horas de uso nocturno) comienzan a afectar negativamente su salud mental autoinformada.

El problema radica en identificar los patrones de comportamiento que preceden a una baja puntuación en la salud mental para que las plataformas puedan implementar estrategias de "Bienestar Digital" (pausas sugeridas, límites de tiempo o cambios en el tipo de contenido).

Pregunta Investigativa

¿En qué medida el tiempo de uso diario y el tipo de dispositivo utilizado influyen en la probabilidad de que un usuario reporte un puntaje de salud mental inferior a 5.0/10 y presente interrupciones en el sueño?

Métricas de Evaluación de Éxito

Para evaluar el éxito del análisis y la validez de las hipótesis planteadas, se definen las siguientes métricas:

- **Puntaje de Alerta de Bienestar (PAB):** Porcentaje de la muestra que presenta una combinación de "Uso Crítico" (>5 horas diarias) y "Baja Autopercepción de Salud" (Score < 5). El éxito se define al identificar los umbrales exactos donde el score de salud mental cae significativamente.
- **Coeficiente de Correlación de Disrupción (CCD):** Medición de la fuerza de asociación entre el uso en horarios nocturnos (Late Night) y la variable de disrupción del sueño (sleep_disruption). Se considerará un hallazgo relevante una correlación $r > 0.60$.
- **Índice de Fatiga por Interacción:** Identificación de la relación entre la tasa de clics en publicidad (ad_click_rate) y el estado de ánimo durante el scroll (mood_while_scrolling). El éxito se mide al determinar si la fatiga digital reduce la efectividad publicitaria en usuarios con salud mental afectada.

Fuentes de Datos

Para el desarrollo de este proyecto se utilizará un conjunto de datos sintético que simula el comportamiento de usuarios en diversas plataformas digitales.

- **Nombre del Dataset:** Social Media User Behavior Dataset
- **Origen:** Kaggle (Autor: Hamna Munir)
- **Enlace:**
<https://www.kaggle.com/datasets/hamnamunir/social-media-user-behavior-dataset>
- **Formato:** Archivo de valores separados por comas (.CSV)
- **Tamaño:** 2,000 filas y 34 columnas.
- **Licencia:** CC0: Public Domain.

La unidad mínima de registro (granularidad) es por usuario individual. Cada fila representa el comportamiento consolidado y perfil de un único usuario (user_id), permitiendo realizar análisis tanto a nivel demográfico como conductual.

Diccionario de Datos Completo (34 Variables)

Variable	Tipo de Dato	Descripción / Rango de Valores
user_id	Alfanumérico ▾	Identificador único del registro (USR00001–USR02000).
age	Numérico (Int) ▾	Edad del usuario (13 a 57 años). Media: 27 años.
gender	Categorico ▾	Identidad de género: Female (49%), Male (46%), Non-binary, Other.
country	Categorico ▾	País de residencia (10 países, principales: Pakistán e India).

profession	Categorico ▾	Ocupación del usuario (Ingeniero, Maestro, Estudiante, etc.).
primary_platform	Categorico ▾	Plataforma principal: Instagram (21%), TikTok (20%), YouTube, etc.
platforms_used_count	Numérico (Int) ▾	Cantidad de redes sociales activas (Rango: 1 a 5).
daily_usage_hours	Numérico (Float) ▾	Horas diarias de uso (0.5 a 12h). Media: 2.99h.
sessions_per_day	Numérico (Int) ▾	Número de sesiones diarias abiertas (1 a 15). Media: 5.02.
avg_session_duration_min	Numérico (Float) ▾	Duración promedio por sesión en minutos (3.3 a 594 min).
preferred_device	Categorico ▾	Dispositivo de preferencia (Smartphone, Tablet, Desktop).
peak_usage_time	Categorico ▾	Horario de mayor actividad (Morning, Afternoon, Evening, Late Night).
followers_count	Numérico (Int) ▾	Cantidad de seguidores del perfil.
following_count	Numérico (Int) ▾	Cantidad de cuentas que sigue el usuario.
posts_per_week	Numérico (Int) ▾	Frecuencia de publicaciones semanales.
likes_given_per_day	Numérico (Int) ▾	Cantidad de "Me gusta" otorgados diariamente.
comments_per_day	Numérico (Int) ▾	Cantidad de comentarios realizados al día.
shares_per_day	Numérico (Int) ▾	Frecuencia diaria de contenido compartido.

dms_sent_per_day	Numérico (Int) ▾	Mensajes directos enviados por día.
preferred_content_type	Categorico ▾	Tipo de contenido favorito (Videos, Photos, Memes, Educational).
scroll_speed	Categorico ▾	Velocidad de navegación (Fast, Medium, Slow).
ad_click_rate	Numérico (Float) ▾	Tasa de clics en anuncios publicitarios.
purchased_via_social	Booleano ▾	Indica si ha realizado compras a través de redes (Yes/No).
monthly_spend_via_social	Numérico (Float) ▾	Gasto mensual en USD realizado en redes sociales.
primary_purpose	Categorico ▾	Motivo de uso (Entertainment, Socializing, News, Learning).
sleep_disruption	Categorico ▾	Nivel de afectación en el sueño (No impact, Mild, Moderate, Severe).
mental_health_score	Numérico (Float) ▾	Puntuación autoinformada de salud mental (1.0 a 10.0).
screen_time_concern	Categorico ▾	Nivel de preocupación por el tiempo en pantalla (Yes/No/Maybe).
notification_frequency	Categorico ▾	Frecuencia de notificaciones (Low, Medium, High).
privacy_setting	Categorico ▾	Configuración de privacidad (Public, Private, Friends Only).
influencer_status	Booleano ▾	Indica si el usuario es considerado influencer (Yes/No).
account_join_date	Fecha (YYYY-MM-DD) ▾	Fecha de creación de la cuenta.

mood_while_scrolling	Categorico ▾	Estado de ánimo (Happy, Neutral, Stressed, Bored, Anxious).
takes_social_media_breaks	Booleano ▾	Indica si el usuario toma descansos de las redes (Yes/No).

Exploración de Datos

Para la fase de exploración se utilizó la librería ydata-profiling (antes pandas-profiling), la cual permitió generar un reporte exhaustivo del estado del dataset. A continuación, se detallan los hallazgos principales:

Análisis de Duplicados y Valores Nulos

- **Duplicados:** Tras el análisis, se identificaron 0 registros duplicados. Cada una de las 2,000 filas cuenta con un identificador único (user_id), lo que garantiza que no hay redundancia de información en la muestra.
- **Valores Nulos:** El dataset presenta una integridad del 100%. No se encontraron valores faltantes (Missing Cells: 0) en ninguna de las 34 variables. Esto permite realizar un análisis estadístico robusto sin necesidad de aplicar técnicas de imputación de datos.

Figura 1. Categoría Resumen del Perfilamiento de Datos del Dataset “Social Media User Behavior Dataset”.

Overview

Overview Alerts 10 Reproduction	
Dataset statistics	
Number of variables	34
Number of observations	2000
Missing cells	0
Missing cells (%)	0.0%
Duplicate rows	0
Duplicate rows (%)	0.0%
Total size in memory	2.3 MiB
Average record size in memory	1.2 KiB
Variable types	
Text	1
Numeric	14
Categorical	17
Boolean	1
DateTime	1

Tipos de Datos

El dataset presenta una estructura mixta que facilita diversos tipos de análisis:


- **Variables Numéricas (14):** Incluyen datos enteros y continuos como age, daily_usage_hours, followers_count y mental_health_score.
- **Variables Categóricas (17):** Variables cualitativas como gender, primary_platform, preferred_device y mood_while_scrolling.
- **Variables Booleanas (3):** Datos de tipo Sí/No como influencer_status y takes_social_media_breaks.

Distribuciones Principales

- **Edad (age):** La distribución está sesgada hacia la población joven, con una media de 27 años y un rango que va desde los 13 hasta los 57 años. El grupo de mayor concentración se encuentra entre los 18 y 30 años.
- **Uso Diario (daily_usage_hours):** El promedio de uso es de 2.99 horas al día. Sin embargo, se observa una distribución de "cola larga" donde algunos usuarios alcanzan hasta las 12 horas diarias, lo que representa los casos críticos para nuestro estudio de salud mental.
- **Salud Mental (mental_health_score):** Los puntajes se distribuyen en un rango de 1 a 10, con una tendencia central que permite identificar claramente a los usuarios por debajo del umbral de bienestar definido ($\text{Score} < 5$).

Correlaciones

Figura 2. Categoría Correlaciones del Perfilamiento de Datos del Dataset “Social Media User Behavior Dataset”.



El análisis de correlación de Pearson revela que la mayoría de las variables tienen una asociación lineal muy débil entre sí, lo cual es característico de este dataset. Sin embargo, se identificaron tres puntos clave:

- **Fuerte Correlación Positiva (0.785):** Existe una relación muy alta entre `daily_usage_hours` y `avg_session_duration_min`. Esto confirma la coherencia interna de los datos: los usuarios que pasan más horas totales en redes sociales lo hacen a través de sesiones individuales más prolongadas.
- **Correlación Negativa Moderada (-0.587):** Se observa una relación inversa importante entre `avg_session_duration_min` y `sessions_per_day`. Esto sugiere un patrón de

comportamiento: los usuarios que tienen sesiones muy largas suelen entrar menos veces al día, mientras que los que tienen sesiones cortas tienden a abrir las aplicaciones con mucha mayor frecuencia.

- **Correlación en Salud Mental y Sueño (Hallazgo Crítico):** Contrario a la hipótesis inicial, la correlación entre `daily_usage_hours` y `self_reported_mental_health_score` es casi nula (0.019).
 - De igual forma, la relación entre el uso diario y la interrupción del sueño (`sleep_disruption`) es muy baja (0.033).
 - En este conjunto de datos específico, el impacto en la salud mental no sigue una progresión lineal simple respecto al tiempo de uso. Esto indica que el problema planteado en la Sección I podría ser más complejo y depender de variables cualitativas (como el estado de ánimo o el tipo de contenido) más que de la cantidad de horas exclusivamente.
- **Comportamiento Comercial (0.379):** Existe una correlación positiva moderada entre `purchased_via_social_media` y `monthly_spend_via_social_usd`, lo cual valida que los usuarios que reportan realizar compras efectivamente reflejan un gasto mensual en la plataforma.


Resumen Estadístico

Métrica	Valor
Número de variables	34
Número de observaciones	2,000
Media de uso diario	2.99 horas
Promedio de sesiones	5.02 al día
Promedio salud mental	Variable (Rango 1-10)
Plataforma líder	Instagram (21%)

Descripción de Necesidades de Limpieza

- **Duplicados:** Se detectaron 0 duplicados.
 - **Justificación:** Esto indica que la integridad de los registros es alta y no hay riesgo de sobreestimar métricas de comportamiento (como el promedio de horas de uso) por repetición de filas.
- **Valores Nulos:** Existen 0 valores nulos.
 - **Justificación:** El dataset es robusto para el análisis estadístico inmediato. Sin embargo, se mantendrá una lógica de imputación preventiva en el código por si se agregan datos futuros con vacíos.
- **Tipos de Datos:** Actualmente existen 19 variables tipo object (texto).
 - **Necesidad:** Las variables como gender, primary_platform y peak_usage_time deben convertirse al tipo category para ahorrar memoria y mejorar la velocidad de procesamiento. La columna account_join_date debe pasar de object a datetime para poder hacer cálculos de antigüedad.
- **Valores Atípicos (Outliers):** El promedio es 47.5 min, pero el máximo es 594 min (casi 10 horas en una sola sesión)
 - **Necesidad:** Estas "sesiones maratónicas" pueden distorsionar los promedios. Se necesita visualizarlas con diagramas de caja (boxplots) para decidir si son errores de registro o comportamientos de uso extremo real.
- **Granularidad:** El dataset tiene una granularidad alta (un registro por cada usuario).
 - **Necesidad:** Para responder a preguntas de negocio globales, se necesita reducir la granularidad (agrupar) para ver promedios por plataforma o por rango de edad.

Figura 3. Resultados del código para la descripción de necesidades de limpieza.



Limpieza y Transformación de Datos


Ajuste de Tipos de Datos (Transformación ejecutada)

Se realizó una reestructuración de los tipos de datos para optimizar el análisis, logrando los siguientes cambios:

- **Conversión Temporal:** La columna `account_join_date` se transformó exitosamente a `datetime64[ns]`, permitiendo el manejo cronológico de la información.
- **Categorización:** Se convirtieron 14 variables de texto (object) a tipo `category`. Esto no solo optimiza el uso de memoria, sino que prepara el dataset para modelos estadísticos más eficientes. Las variables restantes (como IDs o booleanos) se mantuvieron en su formato original para preservar su naturaleza.

Detección y Tratamiento de Valores Atípicos (Outliers)

Figura 4. Boxplot para la identificación de valores atípicos.



- **Análisis Visual:** Se generaron Boxplots para las variables numéricas, identificando una dispersión crítica en `avg_session_duration_min`.
- **Hallazgo:** Se detectaron 155 valores que superaban el límite estadístico de 111.54 minutos, con extremos que alcanzaban los 594 minutos.

- **Tratamiento aplicado:** Se utilizó la técnica de Winsorización a través del método `.clip(upper=111.54)`. Esto permitió "topar" los valores extremos, reduciendo la desviación estándar de 51.1 a 30.5 y logrando una distribución más equilibrada.

Correcciones de Valores y Estandarización

- **Mapeo de Sentimientos:** Se implementó la función `.map()` para crear la columna `mood_category`. Esta transformación simplificó 5 estados de ánimo complejos en 3 categorías maestras (Positivo, Neutral, Negativo), lo cual es fundamental para la validación de la pregunta de investigación.
- **Normalización:** Se aplicó `.replace()` en la variable `preferred_device` para ajustar la terminología (ej. cambiar "Smartphone" por "Celular"), demostrando la capacidad de estandarizar etiquetas de texto.

Agregación de Datos (Cambio de Granularidad)

- **Procedimiento:** Se aplicó una reducción de granularidad utilizando la función `.groupby()`. Se pasó de un nivel de detalle Individual (2,000 registros de usuarios) a un nivel de detalle Agrupado por Plataforma y Sentimiento.
- **Resultado:** Se generó una tabla resumen que permite identificar patrones de comportamiento grupal. Por ejemplo:
 - En Instagram, los usuarios con sentimiento "Neutral" presentan el mayor tiempo de uso promedio (3.55 horas).
 - En Pinterest, a pesar de tener una muestra menor, se observa el promedio de salud mental más alto (6.66) en usuarios con sentimientos negativos, lo que sugiere una dinámica distinta a otras redes.
- **Justificación:** Este cambio de granularidad es necesario para responder a los objetivos de negocio, ya que permite comparar el desempeño de las métricas de bienestar entre diferentes plataformas de manera directa y simplificada.

Validación


Una vez finalizado el proceso de limpieza y transformación, se procedió a validar si el conjunto de datos resultante es apto para abordar los objetivos iniciales del proyecto:

1. **Complejidad de los Datos:** Se confirmó que el dataset no presenta valores nulos en columnas críticas como Salud_Mental_Promedio o Uso_Promedio_Hrs. La técnica de Winsorización aplicada permitió mantener los 2,000 registros originales sin perder la representatividad de los usuarios intensivos, pero estabilizando los promedios.
2. **Relevancia de las Variables:** La creación de la columna mood_category demostró ser pertinente, ya que simplifica la relación entre el estado emocional y la plataforma utilizada, permitiendo responder con mayor claridad a la pregunta investigativa sobre el impacto en la salud mental.
3. **Granularidad Adecuada:** El nivel de detalle obtenido en la tabla agregada es suficiente para proporcionar insights significativos a nivel de plataforma. Se valida que el dataset limpio contiene toda la información necesaria para proceder a la fase de análisis estadístico avanzado.

Análisis de Datos, Exploración del Dataset y Validación de Hipótesis

Para dar respuesta a la pregunta investigativa y cumplir con los objetivos del proyecto, se procedió a cargar el conjunto de datos limpio en la herramienta Power BI. La exploración no se limitó a un enfoque estadístico descriptivo aislado, sino al diseño de un entorno visual interactivo (Dashboard) estructurado bajo la metodología de *Storytelling* de datos, lo que permitió contrastar las variables cuantitativas con los factores cualitativos y contextuales de la muestra.

Figura 5. Vista general del análisis demográfico y tipologías de usuario en Power BI.



Análisis Analítico del Tablero: Página 1 (Perfil del Consumidor y Tipologías de Uso)

El primer lienzo del dashboard se enfocó en consolidar los indicadores demográficos clave y mapear el comportamiento general de los 2,000 usuarios evaluados:

- **Indicadores de Control (KPIs):** Se establecieron tarjetas con métricas promedio para fijar la línea base del ecosistema analizado, confirmando un promedio de edad


de 26.99 años, un consumo digital de 2.99 horas diarias y una frecuencia de 5.02 sesiones por día.

- **Segmentación por Propósito y Plataforma:** Mediante un gráfico de columnas agrupadas, se identificó que plataformas como Instagram y TikTok lideran los conteos de usuarios, estando fuertemente indexadas a propósitos de "Entretenimiento" y "Socializar", mientras que redes como YouTube y LinkedIn muestran una distribución orientada al "Aprendizaje" y "Negocios/Marketing".
- **Validación Empírica de Tipologías:** En la entrega anterior (EA2) se propuso matemáticamente la existencia de dos perfiles de usuario. El Gráfico de Dispersión integrado en esta sección (cruzando el promedio de duración de la sesión frente a las sesiones por día) validó visualmente esta segmentación:
 1. *Usuarios Maratón:* Concentrados en el cuadrante inferior derecho (pocas sesiones al día, pero con duraciones individuales extensas que superan los 45 minutos).
 2. *Usuarios Fragmentados:* Ubicados en el cuadrante superior izquierdo (múltiples accesos cortos a lo largo del día, con sesiones inferiores a los 15 minutos).
- **Distribución Emocional:** El gráfico de anillo basado en la variable transformada mood_category demostró que la categoría Neutral rige la mayor parte de las interacciones, seguida por una proporción equilibrada pero crítica de estados Negativos (ansiedad, estrés y aburrimiento concentrados) y Positivos.

Análisis de Impacto y Validación de Hipótesis: Página 2 (Salud Mental y Bienestar)

El segundo lienzo del dashboard se diseñó específicamente como el núcleo de validación científica de las hipótesis planteadas al inicio de la investigación, utilizando gráficos avanzados para evitar redundancia visual y maximizar la claridad ejecutiva.

Figura 6. Matriz de mapa de calor e indicadores de validación de hipótesis en Power BI.



Validación de la Hipótesis 1 (H1)

- **Enunciado Inicial:** *El tiempo total de exposición a pantallas (horas diarias) predice de manera directa y proporcional el deterioro de la salud mental del usuario.*
- **Análisis Visual y Estadístico:** Para contrastar esta premisa, se implementó un gráfico de columnas agrupadas que evalúa el promedio de horas de uso diario (daily_usage_hours) asignado de manera individual a cada uno de los puntajes de la escala de salud mental auto-reportada (self_reported_mental_health_score, del 1 al 10).
- **Resultado:** Refutada. El gráfico demostró un comportamiento atípico para la creencia popular pero concordante con nuestro coeficiente de Pearson ($r = 0.019$): la altura de todas las columnas se mantiene prácticamente plana y simétrica, promediando de forma constante ~3 horas de uso diario. Un usuario con un estado de salud mental crítico (score de 2.0) registra el mismo tiempo de conexión que un usuario con un bienestar psicológico óptimo (score de 9.0). Por lo tanto, el volumen cuantitativo de tiempo, analizado de forma aislada, no es un

predictor de riesgo de salud mental.

Validación de la Hipótesis 2 (H2)

- **Enunciado Inicial:** *El horario de consumo nocturno o de madrugada altera los ciclos biológicos, incrementando significativamente la gravedad de la disrupción del sueño.*
- **Análisis Visual y Estadístico:** Esta hipótesis conforma la base del Coeficiente de Correlación de Disrupción (CCD). Para su exploración, se estructuró una Matriz de Coincidencias configurada como Mapa de Calor, cruzando los horarios pico de mayor actividad (peak_usage_time) contra los niveles de afectación reportados (sleep_disruption).
- **Resultado:** Apoyada. Al activar el formato condicional por intensidad de color de fondo sobre el conteo de usuarios (user_id), el tablero encendió una alerta visual inmediata en el cruce de la fila Late Night (Madrugada) con la columna Severe impact (Impacto severo). A diferencia de los usuarios matutinos o vespertinos, quienes navegan en la madrugada muestran una concentración de anomalías severas y moderadas en el sueño estadísticamente superior, validando que el *momento del día* en que se interactúa con la interfaz es un factor de riesgo crítico.

Descubrimientos Inesperados y Hallazgos Cualitativos

El análisis cruzado en el dashboard expuso un hallazgo imprevisto: el verdadero catalizador del desgaste psicológico no es el dispositivo o el tiempo, sino la experiencia cualitativa reflejada en la variable mood_category. Al mapear esta categoría mediante un gráfico de barras horizontales frente al promedio del score de salud mental, se evidenció de forma contundente que los usuarios clasificados bajo el espectro "Negativo" exhiben las caídas más profundas en su bienestar. Esto demuestra que el estado emocional en el que el usuario se encuentra al hacer scroll interactúa como el predictor real del riesgo.


Conclusiones

A través de la integración del procesamiento en Python y la consolidación del tablero analítico en Power BI, se dio respuesta definitiva al objetivo general y a la pregunta de investigación planteada:

1. La influencia del consumo de redes sociales sobre el bienestar humano no se rige bajo un modelo lineal directo basado en la cantidad de horas de conexión o en el tipo de dispositivo de preferencia.
2. Los verdaderos detonantes del riesgo son de naturaleza cualitativa, conductual y cronológica: la disrupción grave del sueño está estrechamente ligada al hábito de consumo en la madrugada (*Late Night*), mientras que los puntajes bajos en salud mental (< 5.0) se autoperceptúan mayoritariamente cuando la navegación se realiza bajo estados de ánimo negativos (ansiedad, estrés o aburrimiento crónico).
3. Para el desarrollo de futuras estrategias eficaces de "Bienestar Digital", las métricas de control de las aplicaciones no deben enfocarse únicamente en restringir el tiempo de pantalla, sino en emitir alertas inteligentes basadas en patrones de uso nocturno y en la detección de dinámicas de navegación emocionalmente adversas.

Anexos

Figura 7. Pantallazo del tablero en Trello.



Trello:

<https://trello.com/invite/b/69f1764a9fd7a780d417aa6a/ATTI8383c110c2e84874c118610022244c7824000C68/proyecto-integrado-iii-analitica-de-datos>

GitHub: <https://github.com/Isa-av/Proyecto-Integrado-III>

Referencias

Hamna Munir. (n.d.). *Social Media User Behavior Dataset*. Kaggle.

https://www.kaggle.com/datasets/hamnamunir/social-media-user-behavior-dataset/dataset?select=social_media_user_behavior.csv